DISCURSO DE LA PRESENTACIÓN · BASE PARA ARTÍCULO ACADÉMICO

Rechazo calibrado y expansión a la sección en un asistente RAG de cumplimiento normativo para la investigación clínica

Texto íntegro de la exposición oral en siete partes, una por diapositiva, calibrado para ocho minutos como máximo a ritmo tranquilo; con la correspondencia a las secciones de un artículo, resúmenes en español e inglés, amenazas a la validez y referencias.

David Naranjo Ramírez · Noviembre de 2026 · Versión 1.0

Proyecto final del módulo de IA Generativa · Máster en Data Science & IA · Evolve Academy

github.com/dnarram/clinical-research-compliance-assistant

Índice

Nota previa: cómo usar este documento

I. Apertura

II. El problema

III. Cómo está construido

IV. El prompt

V. La demostración

VI. La evaluación

VII. Límites, siguientes pasos y cierre

Anexo. Del discurso al artículo

Nota previa: cómo usar este documento

El texto está escrito para ser **dicho**: frases completas, en primera persona y en el orden de las siete diapositivas. Cada parte corresponde además a una o varias secciones de un artículo con estructura IMRaD (introducción, métodos, resultados y discusión); el anexo amplía lo que la exposición oral no puede desarrollar (preguntas de investigación, amenazas a la validez, resúmenes, referencias).

Parte del discurso	Diapositiva	Sección del artículo
I. Apertura	1 · Portada	Título y resumen
II. El problema	2 · El problema	Introducción y motivación
III. Cómo está construido	3 · Arquitectura	Métodos: corpus y sistema
IV. El prompt	4 · El system prompt	Métodos: diseño de instrucciones
V. La demostración	5 · Demo en vivo	Resultados: ejemplos cualitativos
VI. La evaluación	6 · Evaluación	Métodos de evaluación y resultados
VII. Límites, siguientes pasos y cierre	7 · Límites	Limitaciones, trabajo futuro y conclusiones

Leído en voz alta a ritmo tranquilo, el cuerpo dura unos ocho minutos (unas mil palabras); la demo en vivo de la parte V añade el tiempo de las cuatro preguntas. Las partes que la exposición no cubre —objetivos formales, discusión y amenazas a la validez— están en el anexo.

I. Apertura

Buenos días. Presento un asistente de pregunta y respuesta para el cumplimiento normativo en investigación clínica. Responde sobre tres normas —la ICH E6(R3) de Buenas Prácticas Clínicas, la ICH E2A de notificación de seguridad y la Declaración de Helsinki—, en español o en inglés, cita literalmente documento, sección y página, recuerda la conversación y rechaza lo que sus fuentes no cubren. En ocho minutos: el problema, cómo está construido, el prompt, una demo y qué dicen los números.

II. El problema

Viernes, 17:50. Un monitor recibe el aviso de un acontecimiento adverso grave. ¿Es un SUSAR? ¿Quién lo notifica, a quién, en qué plazo? La respuesta está repartida entre tres documentos, noventa páginas en inglés, y en este ámbito no basta con responder: hay que demostrar de dónde sale. En una inspección no vale «creo que eran quince días»; vale «E2A, sección III.B, página 7». La trazabilidad es el requisito.

Un asistente generalista no sirve, porque un modelo de lenguaje puede inventar un plazo con total aplomo. RAG ataca eso: buscar primero en documentos cerrados y responder solo con lo encontrado. Elegí este dominio porque cinco años de soporte a software de ensayos clínicos y la certificación ICH GCP me permiten juzgar si una respuesta es correcta.

III. Cómo está construido

Tres documentos públicos, 801 fragmentos, cada uno con documento, sección y página. Los documentos se descargan de los editores y se verifican con su huella; Helsinki se indexó desde la web porque el PDF estropea los números de párrafo.

Descarté el agente que decide por sí mismo si busca: el enunciado exige usar la base en cada consulta. El agente es un grafo fijo de cuatro nodos: reescribir, recuperar, generar, rechazar. La reescritura convierte la pregunta, con el historial, en una pregunta autónoma en inglés: así resuelve «¿y para las demás?» y salva el idioma del corpus.

La recuperación tiene cuatro etapas. Primero, la puerta: si la mejor puntuación no alcanza 0,69, la pregunta se rechaza con una plantilla sin llamar al modelo; lo que no llega al modelo no se puede inventar. Segundo, si la pregunta nombra documentos, las seis plazas se reparten entre ellos. Tercero, diversidad. Cuarto, la etapa más útil: cada fragmento se amplía a su sección completa. Nació de un fallo real: la definición de «grave» tiene cinco criterios, el fragmento traía dos y el modelo la daba por completa. No se arregla pidiéndoselo, porque no puede completar lo que no ve; se arregla entregándole la sección entera.

Tres decisiones que defiendo: una caché de embeddings versionada, porque el plan gratuito permite mil textos al día y el corpus consume ochocientos; un umbral calibrado con datos, no fijado a ojo; y una memoria de diez mensajes que mantiene los pasajes fuera del historial.

IV. El prompt

Cuatro versiones documentadas. La primera, el prompt de clase, respondía bien pero sin citas. La tercera añadió citas por frase, atribución cuando las normas difieren y la política de idioma. Al leer todas las respuestas de la evaluación aparecieron tres fallos: una pregunta de varios pasos rechazada entera, su rechazo en español escrito en inglés y listas cortadas dadas por completas. La cuarta gradúa el rechazo, construye las cadenas paso a paso y exige listas completas. El principio: las restricciones duras van en el código; el criterio, en el prompt.

V. La demostración

Paso a la aplicación. Primera pregunta, en inglés, el plazo de una reacción mortal inesperada: fijaos en las citas y en el panel de fuentes: siete días naturales y ocho más para el informe completo. Segunda, en español y en el mismo hilo, «¿y para las demás reacciones graves e inesperadas?»: la reescritura resuelve la referencia y la respuesta vuelve en español con la norma citada en inglés: quince días. Memoria y política de idioma en un solo turno. Tercera, qué exigen la E6(R3) y Helsinki para incluir a quien no puede consentir: dos documentos nombrados, dos posturas contrastadas, cada una con su cita. Cuarta, qué fármaco GLP-1 es mejor para adelgazar: es consejo clínico; la puerta la rechaza con 0,64 y el modelo nunca la ve.

VI. La evaluación

Antes de conectar el modelo comprobé la recuperación sola: doce consultas del dominio, en inglés y en español, y seis ajenas. Los dos grupos no se solapan y el umbral es el punto medio del hueco.

Después, un golden set de 25 preguntas en ambos idiomas, cincuenta ejecuciones, y un juez que compara cada respuesta con una referencia. La versión final sube la corrección juzgada de 0,78 a 0,95, con el mismo juez y la misma puntuación. Como diseñé las correcciones mirando ese conjunto, escribí doce preguntas nuevas tras congelar el sistema y las ejecuté una sola vez: de 0,95 a 1,00, sin regresión. Ninguna pregunta del dominio fue rechazada y todas las ajenas sí.

Dos cautelas. El juez es el mismo modelo que responde, porque el grande permite veinte llamadas al día; en 38 respuestas coinciden en el 79 % y el grande es más estricto, así que las cifras absolutas son optimistas. Y queda un fallo que informo en lugar de ajustar: la cadena de notificación de varios saltos aún pierde un eslabón.

VII. Límites, siguientes pasos y cierre

Hoy el sistema conoce tres documentos, puede perder un salto en preguntas encadenadas, necesita recalibrarse si cambia el corpus y su memoria vive en el proceso. Siguientes pasos, por valor: descomponer las preguntas de varios saltos, añadir la farmacovigilancia europea y el Reglamento 536/2014, y un juez de fidelidad.

Cierro con tres frases. Un asistente experto en un dominio regulado no se distingue por el modelo que usa, sino por lo que le impide equivocarse: una puerta calibrada antes de generar, pasajes completos y citas obligatorias. Los fallos que parecen de redacción suelen ser de recuperación. Y la fiabilidad se demuestra con preguntas que el autor no vio. Gracias.

Anexo. Del discurso al artículo

Títulos propuestos

- **Español**: *Rechazo calibrado y expansión a la sección en un asistente RAG de cumplimiento normativo para la investigación clínica: diseño y evaluación con conjunto reservado.*
- **Inglés**: *Calibrated Abstention and Section-Level Context Expansion in a Retrieval-Augmented Assistant for Clinical Research Compliance: Design and Held-Out Evaluation.*

Resumen (borrador, español)

Los modelos de lenguaje generan respuestas plausibles pero no siempre verificables, un riesgo crítico en dominios regulados como la investigación clínica. Presentamos un asistente de generación aumentada con recuperación sobre tres normas (ICH E6(R3), ICH E2A y la Declaración de Helsinki de 2024; 801 fragmentos) que cita cada afirmación a nivel de documento, sección y página, responde en español o en inglés y se abstiene cuando su base no cubre la pregunta. El sistema combina una puerta de relevancia calibrada empíricamente y aplicada antes de la generación, enrutado por documento, selección por relevancia marginal máxima y expansión de cada fragmento a su

sección normativa, orquestados en un grafo de estados explícito con memoria conversacional. Lo evaluamos con un conjunto bilingüe de 25 preguntas (50 ejecuciones), un juez basado en referencias y un conjunto reservado de 12 preguntas redactado tras congelar el sistema. Frente a una configuración base, la corrección juzgada pasó de 0,78 a 0,95 en el conjunto de referencia y de 0,95 a 1,00 en el reservado, sin rechazos indebidos y con todas las preguntas ajenas rechazadas. El análisis de errores muestra que los fallos aparentemente de redacción (listas incompletas) se originaban en la recuperación, y que las preguntas de varios saltos siguen siendo la principal limitación. Discutimos el sesgo de autopreferencia del juez (78,9 % de acuerdo con un juez mayor y más estricto) y otras amenazas a la validez.

Abstract (draft, English)

Large language models produce fluent but not always verifiable answers, a critical risk in regulated domains such as clinical research. We present a retrieval-augmented assistant over three regulatory texts (ICH E6(R3), ICH E2A and the 2024 Declaration of Helsinki; 801 chunks) that cites every claim at document, section and page level, answers in Spanish or English, and abstains when its knowledge base does not cover the question. The system combines an empirically calibrated relevance gate applied before generation, document routing, maximal marginal relevance selection and section-level context expansion, orchestrated as an explicit state graph with conversational memory. We evaluate it with a bilingual golden set of 25 questions (50 runs), a reference-based LLM judge, and a 12-question held-out set written after the system was frozen. Compared with a baseline configuration, judged correctness rose from 0.78 to 0.95 on the golden set and from 0.95 to 1.00 on the held-out set, with no false refusals and all out-of-domain questions refused. Error analysis shows that apparent generation failures (truncated lists) originated in retrieval, and that multi-hop questions remain the main limitation. We discuss judge self-preference (78.9 % exact agreement with a larger, stricter judge) and other threats to validity.

Palabras clave

Generación aumentada con recuperación; abstención; investigación clínica; Buenas Prácticas Clínicas; cumplimiento normativo; evaluación de modelos de lenguaje; LLM como juez.

Contribuciones que defendería el artículo

1. Una arquitectura RAG para cumplimiento normativo con **abstención previa a la generación** mediante un umbral calibrado sobre la distribución de puntuaciones de consultas del dominio y ajenas.
2. La **expansión a la sección normativa** como corrección de la truncación de listas, con su justificación cuantitativa (presupuesto de 4.000 caracteres; 393 de 399 secciones).
3. Un **protocolo de evaluación en cuatro capas** (calibración, conjunto de referencia bilingüe, juez con referencias y conjunto reservado) aplicable con recursos gratuitos.
4. Un **análisis de errores** que separa fallos de recuperación y de generación, con el principio de diseño «restricciones duras en código, criterio en el prompt».
5. Un **artefacto reproducible**: código abierto, caché de embeddings versionada, respuestas y veredictos guardados.

Estructura propuesta

Sección del artículo	Contenido	Partes del discurso
1. Introducción	Problema, trazabilidad, alucinación, preguntas de investigación	II + anexo
2. Trabajo relacionado	RAG, abstención, MMR, evaluación de RAG, LLM como juez, recuperación multisalto	(por redactar)
3. Corpus	Fuentes, preprocesado, troceado, procedencia	III
4. Sistema	Grafo, reescritura e idioma, recuperación en cuatro etapas, memoria, ingeniería	III
5. Diseño de instrucciones	Versiones v1–v4 y observaciones	IV
6. Evaluación	Calibración, conjunto de referencia, juez, conjunto reservado, métricas	VI
7. Resultados	Tablas, ejemplos cualitativos, análisis de errores	V, VI
8. Discusión	Respuesta a las preguntas, amenazas a la validez	anexo
9. Limitaciones y trabajo futuro		VII
10. Conclusiones		VII

Tablas y figuras disponibles

Elemento	Archivo de origen
Diagrama del grafo	`docs/img/graph.png`
Distribución de puntuaciones y umbral	`docs/img/calibration.png` ; datos en `data/kb/calibration.json`
Captura de la aplicación	`docs/img/app.png`
Resultados por pregunta, configuración final	`docs/evaluation.md` , `data/eval/answers.jsonl`
Resultados por pregunta, configuración base	`docs/evaluation_baseline_v3.md` , `data/eval/answers_baseline_v3.jsonl`
Conjunto reservado	`docs/heldout_evaluation.md` , `docs/heldout_baseline_v3.md` , `data/eval/heldout*.jsonl`
Veredictos del juez	`data/eval/*.judge-gemini-3.5-flash-lite.jsonl` y `.md` ; comparación con el juez mayor en `*.judge-gemini-3.5-flash.jsonl`
Prompts completos	`src/compliance_assistant/prompts.py` ; observaciones en `docs/prompt_iterations.md`
Registro de decisiones	`docs/decisions.md`

Trabajo pendiente antes de enviar

1. **Ablación**: evaluar el prompt v4 sin expansión ni enrutado para aislar su efecto (`scripts/03_evaluate.py --prompt-version v4 --no-expand --no-routing --with-answers`).
2. **Acuerdo entre jueces**: calcular la kappa de Cohen y calificar a mano una submuestra para medir el acuerdo humano-juez.
3. **Incertidumbre**: intervalos de confianza por *bootstrap* para la corrección juzgada y un contraste pareado entre configuraciones.
4. **Fidelidad**: un juez de afirmación frente a pasaje citado sobre todas las respuestas.
5. **Calibración independiente**: separar las consultas de calibración de las de evaluación y de la demo.
6. **Ampliar el conjunto reservado** y, si es posible, que lo redacte o revise otro experto.
7. **Trabajo relacionado**: redactar la sección 2 con las referencias de abajo y otras recientes.

Declaraciones

- **Disponibilidad**: código, caché de embeddings, conjuntos de evaluación, respuestas y veredictos en https://github.com/dnarram/clinical-research-compliance-assistant. Los documentos fuente no se redistribuyen; se descargan de sus editores y se verifican con SHA-256.
- **Uso de IA**: el desarrollo contó con un asistente de programación basado en IA, y el conjunto de referencia y las respuestas de referencia se redactaron con asistencia de IA a partir del texto verificado y fueron revisados por el autor. Conviene declararlo según la política de la revista o del congreso elegido.
- **Destinos posibles**: congresos y revistas de informática médica o biomédica, por ejemplo *Medical Informatics Europe* (MIE) o el *Journal of Biomedical Informatics*. Conviene revisar su alcance y sus normas antes de decidir.

Referencias

Verificar DOI, páginas y ediciones antes del envío.

- Carbonell, J. y Goldstein, J. (1998). The use of MMR, diversity-based reranking for reordering documents and producing summaries. *Proceedings of SIGIR '98*.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1).
- Es, S., James, J., Espinosa-Anke, L. y Schockaert, S. (2024). RAGAS: Automated evaluation of retrieval augmented generation. *Proceedings of EACL 2024: System Demonstrations*.
- Gao, Y. et al. (2023). Retrieval-augmented generation for large language models: A survey. *arXiv:2312.10997*.
- International Council for Harmonisation (1994). *ICH E2A: Clinical Safety Data Management: Definitions and Standards for Expedited Reporting*.
- International Council for Harmonisation (2025). *ICH E6(R3): Guideline for Good Clinical Practice*, Step 4, 6 de enero de 2025.

- Ji, Z. et al. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12).
- Lewis, P. et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems 33*.
- Liu, N. F. et al. (2024). Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12.
- Panickssery, A., Bowman, S. R. y Feng, S. (2024). LLM evaluators recognize and favor their own generations. *Advances in Neural Information Processing Systems 37*.
- Robertson, S. y Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4).
- Trivedi, H. et al. (2023). Interleaving retrieval with chain-of-thought reasoning for knowledge-intensive multi-step questions. *Proceedings of ACL 2023*.
- World Medical Association (2024). *Declaration of Helsinki: Ethical Principles for Medical Research Involving Human Participants*, 75.ª Asamblea General, Helsinki, octubre de 2024.
- Zheng, L. et al. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track*.



Documento elaborado con la identidad visual DNR (manual de marca v2.0). Fuente editable: `docs/articulo/discurso_presentacion_es.md`.