DISCURSO DE LA PRESENTACIÓN · BASE PARA ARTÍCULO ACADÉMICO

Rechazo calibrado y expansión a la sección en un asistente RAG de cumplimiento normativo para la investigación clínica

Texto íntegro de la exposición oral en siete partes, una por diapositiva, calibrado para ocho minutos como máximo a ritmo tranquilo; con la correspondencia a las secciones de un artículo, resúmenes en español e inglés, amenazas a la validez y referencias.

David Naranjo Ramírez · Noviembre de 2026 · Versión 1.0

Proyecto final del módulo de IA Generativa · Máster en Data Science & IA · Evolve Academy

github.com/dnarram/clinical-research-compliance-assistant

Índice

Nota previa: cómo usar este documento

I. Apertura

II. El problema

III. Cómo está construido

IV. El prompt

V. La demostración

VI. La evaluación

VII. Límites, siguientes pasos y cierre

Anexo. Del discurso al artículo

Nota previa: cómo usar este documento

El texto está escrito para ser **dicho**, no leído: primera persona, tono cercano, frases cortas y en el orden de las siete diapositivas. Cada parte corresponde además a una o varias secciones de un artículo con estructura IMRaD (introducción, métodos, resultados y discusión); el anexo amplía lo que la exposición oral no puede desarrollar (preguntas de investigación, amenazas a la validez, resúmenes, referencias).

Parte del discurso	Diapositiva	Sección del artículo
I. Apertura	1 · Portada	Título y resumen
II. El problema	2 · El problema	Introducción y motivación
III. Cómo está construido	3 · Arquitectura	Métodos: corpus y sistema
IV. El prompt	4 · El system prompt	Métodos: diseño de instrucciones
V. La demostración	5 · Demo en vivo	Resultados: ejemplos cualitativos
VI. La evaluación	6 · Evaluación	Métodos de evaluación y resultados
VII. Límites, siguientes pasos y cierre	7 · Límites	Limitaciones, trabajo futuro y conclusiones

Leído en voz alta a ritmo tranquilo, el cuerpo dura unos ocho minutos (unas mil palabras); la demo en vivo de la parte V añade el tiempo de las cuatro preguntas. Las partes que la exposición no cubre —objetivos formales, discusión y amenazas a la validez— están en el anexo.

I. Apertura

Buenos días. Voy a contaros cómo he construido un asistente que responde sobre normativa de investigación clínica y, sobre todo, por qué me fío de lo que dice. Conoce tres textos: la ICH E6(R3) de Buenas Prácticas Clínicas, la ICH E2A de notificación de seguridad y la Declaración de Helsinki. Contesta en español o en inglés, cita documento, sección y página, recuerda la conversación y, cuando no sabe, lo dice en lugar de inventar. En ocho minutos: el problema, cómo está hecho, el prompt, una demo y qué dicen los números.

II. El problema

Imaginad un viernes, 17:50. Eres monitor de un ensayo clínico y te llega el aviso de un acontecimiento adverso grave. ¿Es un SUSAR? ¿Quién lo notifica, a quién, en cuánto tiempo? La respuesta existe, pero está repartida entre tres documentos, noventa páginas en inglés. Y aquí no basta con acertar: hay que demostrar de dónde sale. En una inspección, «creo que eran quince días» no vale. Vale «E2A, sección III.B, página 7». La trazabilidad no es un extra: es el requisito.

Un chatbot generalista no sirve, porque un modelo de lenguaje es capaz de inventarse un plazo con total seguridad. La idea de RAG es sencilla: buscar primero en documentos cerrados y contestar solo con lo encontrado. Elegí este dominio porque lo conozco: cinco años en soporte de software

de ensayos clínicos y certificación ICH GCP me permiten distinguir una respuesta correcta de una que solo suena bien.

III. Cómo está construido

Por dentro hay tres documentos públicos, troceados en 801 fragmentos, cada uno con su documento, su sección y su página. Los descargo de los editores y verifico su huella digital; Helsinki lo indexé desde la web, porque el PDF me estropeaba los números de párrafo.

Descarté el agente que decide si busca o no: el enunciado pide usar la base en cada consulta. Es un grafo fijo de cuatro nodos: reescribir, recuperar, generar o rechazar. El primero convierte tu pregunta, con el historial, en una pregunta completa y en inglés. Por eso entiende un «¿y para las demás?» y, de paso, busca en el idioma del corpus.

La recuperación tiene cuatro etapas. La primera es una puerta: si la mejor coincidencia no llega a 0,69, la pregunta se rechaza con una plantilla y el modelo ni la ve. Lo que no llega al modelo no se puede inventar. Segunda: si preguntas por varios documentos, las seis plazas se reparten entre ellos. Tercera: variedad, para no traer seis veces lo mismo. Y la cuarta, la que más me ha enseñado: cada fragmento se amplía a su sección completa. Nació de un fallo real. La definición de «grave» tiene cinco criterios; el fragmento traía dos y el modelo la daba por completa. Pedirle que no lo hiciera no sirve: nadie completa lo que no ve. Hay que dárselo entero.

Tres decisiones más: una caché de embeddings versionada, porque el plan gratuito da mil textos al día y el corpus gasta ochocientos; un umbral calibrado con datos, no a ojo; y una memoria de diez mensajes que deja los pasajes fuera del historial.

IV. El prompt

El prompt tiene cuatro versiones documentadas. La primera, la de clase, respondía bien pero sin citas. La tercera añadió una cita por frase, atribución cuando las normas discrepan y política de idioma. Entonces leí una a una las respuestas de la evaluación y aparecieron tres fallos: una pregunta de varios pasos rechazada entera, un rechazo en español escrito en inglés y listas cortadas dadas por completas. La cuarta rechaza con matices, construye las cadenas paso a paso y exige listas completas. Mi principio: las restricciones duras van en el código; el criterio, en el prompt.

V. La demostración

Os lo enseño. Primera pregunta, en inglés: el plazo para notificar una reacción adversa mortal e inesperada. Mirad las citas: siete días, y ocho más para completar el informe. Segunda, ahora en español y en el mismo hilo: «¿y para las demás reacciones graves e inesperadas?». No repito nada: la reescritura entiende la referencia y la respuesta llega en español, con la norma citada en inglés: quince días. Memoria e idioma, en un solo turno. Tercera: qué exigen la E6(R3) y Helsinki para incluir a quien no puede dar su consentimiento. Dos documentos, dos posturas contrastadas, cada una con su cita. Y cuarta, la trampa: qué fármaco GLP-1 es mejor para adelgazar. Es consejo clínico, no está en sus fuentes. La puerta lo rechaza con un 0,64, por debajo del 0,69, y el modelo ni se entera.

VI. La evaluación

¿Y cómo sé que funciona? Antes de conectar el modelo probé solo la recuperación: doce consultas del dominio, en inglés y en español, y seis ajenas. Los dos grupos no se solapan, y el umbral es el punto medio del hueco.

Después, 25 preguntas en ambos idiomas, cincuenta ejecuciones y un juez que compara cada respuesta con una de referencia. Entre la versión tercera y la final, la corrección sube de 0,78 a 0,95, con el mismo juez y la misma puntuación. Pero había ajustado el sistema mirando ese conjunto. Así que, ya congelado, escribí doce preguntas nuevas y las pasé una sola vez: de 0,95 a 1,00, sin retrocesos. Ninguna pregunta del dominio fue rechazada; todas las ajenas, sí.

Dos cautelas, que prefiero contaros yo. El juez es el mismo modelo que responde, porque el grande solo permite veinte llamadas al día; en 38 respuestas coinciden el 79 % y el grande es más estricto, así que las cifras absolutas son algo optimistas. Y queda un fallo que cuento en lugar de maquillar: la cadena de notificación de varios saltos todavía pierde un eslabón.

VII. Límites, siguientes pasos y cierre

Los límites, con franqueza: solo conoce tres documentos, puede perder un salto en preguntas encadenadas, hay que recalibrarlo si cambia el corpus y su memoria vive en el proceso. Lo siguiente: descomponer las preguntas de varios saltos, añadir la farmacovigilancia europea y el Reglamento 536/2014, y un juez de fidelidad a las fuentes.

Me llevo tres ideas. Un asistente experto en un ámbito regulado no se distingue por el modelo que usa, sino por lo que le impide equivocarse: una puerta calibrada, pasajes completos y citas obligatorias. Muchos fallos que parecen de redacción son de recuperación. Y la fiabilidad se demuestra con preguntas que el autor no ha visto. Gracias. ¿Preguntas?

Anexo. Del discurso al artículo

Títulos propuestos

- **Español**: *Rechazo calibrado y expansión a la sección en un asistente RAG de cumplimiento normativo para la investigación clínica: diseño y evaluación con conjunto reservado.*
- **Inglés**: *Calibrated Abstention and Section-Level Context Expansion in a Retrieval-Augmented Assistant for Clinical Research Compliance: Design and Held-Out Evaluation.*

Resumen (borrador, español)

Los modelos de lenguaje generan respuestas plausibles pero no siempre verificables, un riesgo crítico en dominios regulados como la investigación clínica. Presentamos un asistente de generación aumentada con recuperación sobre tres normas (ICH E6(R3), ICH E2A y la Declaración de Helsinki de 2024; 801 fragmentos) que cita cada afirmación a nivel de documento, sección y página, responde en español o en inglés y se abstiene cuando su base no cubre la pregunta. El sistema combina una puerta de relevancia calibrada empíricamente y aplicada antes de la generación, enrutado

por documento, selección por relevancia marginal máxima y expansión de cada fragmento a su sección normativa, orquestados en un grafo de estados explícito con memoria conversacional. Lo evaluamos con un conjunto bilingüe de 25 preguntas (50 ejecuciones), un juez basado en referencias y un conjunto reservado de 12 preguntas redactado tras congelar el sistema. Frente a una configuración base, la corrección juzgada pasó de 0,78 a 0,95 en el conjunto de referencia y de 0,95 a 1,00 en el reservado, sin rechazos indebidos y con todas las preguntas ajenas rechazadas. El análisis de errores muestra que los fallos aparentemente de redacción (listas incompletas) se originaban en la recuperación, y que las preguntas de varios saltos siguen siendo la principal limitación. Discutimos el sesgo de autopreferencia del juez (78,9 % de acuerdo con un juez mayor y más estricto) y otras amenazas a la validez.

Abstract (draft, English)

Large language models produce fluent but not always verifiable answers, a critical risk in regulated domains such as clinical research. We present a retrieval-augmented assistant over three regulatory texts (ICH E6(R3), ICH E2A and the 2024 Declaration of Helsinki; 801 chunks) that cites every claim at document, section and page level, answers in Spanish or English, and abstains when its knowledge base does not cover the question. The system combines an empirically calibrated relevance gate applied before generation, document routing, maximal marginal relevance selection and section-level context expansion, orchestrated as an explicit state graph with conversational memory. We evaluate it with a bilingual golden set of 25 questions (50 runs), a reference-based LLM judge, and a 12-question held-out set written after the system was frozen. Compared with a baseline configuration, judged correctness rose from 0.78 to 0.95 on the golden set and from 0.95 to 1.00 on the held-out set, with no false refusals and all out-of-domain questions refused. Error analysis shows that apparent generation failures (truncated lists) originated in retrieval, and that multi-hop questions remain the main limitation. We discuss judge self-preference (78.9 % exact agreement with a larger, stricter judge) and other threats to validity.

Palabras clave

Generación aumentada con recuperación; abstención; investigación clínica; Buenas Prácticas Clínicas; cumplimiento normativo; evaluación de modelos de lenguaje; LLM como juez.

Contribuciones que defendería el artículo

1. Una arquitectura RAG para cumplimiento normativo con **abstención previa a la generación** mediante un umbral calibrado sobre la distribución de puntuaciones de consultas del dominio y ajenas.
2. La **expansión a la sección normativa** como corrección de la truncación de listas, con su justificación cuantitativa (presupuesto de 4.000 caracteres; 393 de 399 secciones).
3. Un **protocolo de evaluación en cuatro capas** (calibración, conjunto de referencia bilingüe, juez con referencias y conjunto reservado) aplicable con recursos gratuitos.
4. Un **análisis de errores** que separa fallos de recuperación y de generación, con el principio de diseño «restricciones duras en código, criterio en el prompt».

5. Un **artefacto reproducible**: código abierto, caché de embeddings versionada, respuestas y veredictos guardados.

Estructura propuesta

Sección del artículo	Contenido	Partes del discurso
1. Introducción	Problema, trazabilidad, alucinación, preguntas de investigación	II + anexo
2. Trabajo relacionado	RAG, abstención, MMR, evaluación de RAG, LLM como juez, recuperación multisalto	(por redactar)
3. Corpus	Fuentes, preprocesado, troceado, procedencia	III
4. Sistema	Grafo, reescritura e idioma, recuperación en cuatro etapas, memoria, ingeniería	III
5. Diseño de instrucciones	Versiones v1–v4 y observaciones	IV
6. Evaluación	Calibración, conjunto de referencia, juez, conjunto reservado, métricas	VI
7. Resultados	Tablas, ejemplos cualitativos, análisis de errores	V, VI
8. Discusión	Respuesta a las preguntas, amenazas a la validez	anexo
9. Limitaciones y trabajo futuro		VII
10. Conclusiones		VII

Tablas y figuras disponibles

Elemento	Archivo de origen
Diagrama del grafo	`docs/img/graph.png`
Distribución de puntuaciones y umbral	`docs/img/calibration.png` ; datos en `data/kb/calibration.json`
Captura de la aplicación	`docs/img/app.png`
Resultados por pregunta, configuración final	`docs/evaluation.md` , `data/eval/answers.jsonl`
Resultados por pregunta, configuración base	`docs/evaluation_baseline_v3.md` , `data/eval/answers_baseline_v3.jsonl`
Conjunto reservado	`docs/heldout_evaluation.md` , `docs/heldout_baseline_v3.md` , `data/eval/heldout*.jsonl`
Veredictos del juez	`data/eval/*.judge-gemini-3.5-flash-lite.jsonl` y `.md` ; comparación con el juez mayor en `*.judge-gemini-3.5-flash.jsonl`
Prompts completos	`src/compliance_assistant/prompts.py` ; observaciones en `docs/prompt_iterations.md`

Elemento	Archivo de origen
Registro de decisiones	`docs/decisions.md`

Trabajo pendiente antes de enviar

1. **Ablación**: evaluar el prompt v4 sin expansión ni enrutado para aislar su efecto (`scripts/03_evaluate.py --prompt-version v4 --no-expand --no-routing --with-answers`).
2. **Acuerdo entre jueces**: calcular la kappa de Cohen y calificar a mano una submuestra para medir el acuerdo humano-juez.
3. **Incertidumbre**: intervalos de confianza por *bootstrap* para la corrección juzgada y un contraste pareado entre configuraciones.
4. **Fidelidad**: un juez de afirmación frente a pasaje citado sobre todas las respuestas.
5. **Calibración independiente**: separar las consultas de calibración de las de evaluación y de la demo.
6. **Ampliar el conjunto reservado** y, si es posible, que lo redacte o revise otro experto.
7. **Trabajo relacionado**: redactar la sección 2 con las referencias de abajo y otras recientes.

Declaraciones

- **Disponibilidad**: código, caché de embeddings, conjuntos de evaluación, respuestas y veredictos en https://github.com/dnarram/clinical-research-compliance-assistant. Los documentos fuente no se redistribuyen; se descargan de sus editores y se verifican con SHA-256.
- **Uso de IA**: el desarrollo contó con un asistente de programación basado en IA, y el conjunto de referencia y las respuestas de referencia se redactaron con asistencia de IA a partir del texto verificado y fueron revisados por el autor. Conviene declararlo según la política de la revista o del congreso elegido.
- **Destinos posibles**: congresos y revistas de informática médica o biomédica, por ejemplo *Medical Informatics Europe* (MIE) o el *Journal of Biomedical Informatics*. Conviene revisar su alcance y sus normas antes de decidir.

Referencias

Verificar DOI, páginas y ediciones antes del envío.

- Carbonell, J. y Goldstein, J. (1998). The use of MMR, diversity-based reranking for reordering documents and producing summaries. *Proceedings of SIGIR '98*.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1).
- Es, S., James, J., Espinosa-Anke, L. y Schockaert, S. (2024). RAGAS: Automated evaluation of retrieval augmented generation. *Proceedings of EACL 2024: System Demonstrations*.
- Gao, Y. et al. (2023). Retrieval-augmented generation for large language models: A survey. *arXiv:2312.10997*.

- International Council for Harmonisation (1994). *ICH E2A: Clinical Safety Data Management: Definitions and Standards for Expedited Reporting*.
- International Council for Harmonisation (2025). *ICH E6(R3): Guideline for Good Clinical Practice*, Step 4, 6 de enero de 2025.
- Ji, Z. et al. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12).
- Lewis, P. et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems 33*.
- Liu, N. F. et al. (2024). Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12.
- Panickssery, A., Bowman, S. R. y Feng, S. (2024). LLM evaluators recognize and favor their own generations. *Advances in Neural Information Processing Systems 37*.
- Robertson, S. y Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4).
- Trivedi, H. et al. (2023). Interleaving retrieval with chain-of-thought reasoning for knowledge-intensive multi-step questions. *Proceedings of ACL 2023*.
- World Medical Association (2024). *Declaration of Helsinki: Ethical Principles for Medical Research Involving Human Participants*, 75.ª Asamblea General, Helsinki, octubre de 2024.
- Zheng, L. et al. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track*.



Documento elaborado con la identidad visual DNR (manual de marca v2.0). Fuente editable: `docs/articulo/discurso_presentacion_es.md`.