MÓDULO DE IA GENERATIVA · PROYECTO FINAL

Asistente de cumplimiento en investigación clínica

Un agente experto en ICH GCP, notificación expeditiva de seguridad y la Declaración de Helsinki — construido con Gemini, ChromaDB y LangGraph, con memoria y citas literales.

David Naranjo Ramírez Máster en Data Science & IA · Evolve Academy · Noviembre 2026



La pregunta que un CRA hace un viernes a las 17:50

ACABA DE LLEGAR UN SAE

“¿Es un SUSAR? ¿Quién lo notifica, a quién y en qué plazo?”

La respuesta está repartida en tres textos — ICH E2A (plazos), ICH E6(R3) (obligaciones del investigador y del promotor) y la Declaración de Helsinki (ética) — y hay que citarla literalmente, no parafrasearla.

Tres fuentes de referencia, ~90 páginas

ICH E6(R3) GCP (2025) · ICH E2A · Declaración de Helsinki de la AMM (2024)

La trazabilidad es el requisito

Cada afirmación citada a documento, sección y página; rechazar lo que las fuentes no cubren

Por qué yo

5 años dando soporte a software de ensayos clínicos (Medidata Rave, Pfizer, Novo Nordisk) · certificado ICH GCP · proyecto anterior: farmacovigilancia FAERS GLP-1

Un grafo explícito: la base de conocimiento se usa en cada consulta



Base idempotente

801 fragmentos, gemini-embedding-2. Caché de embeddings versionada + manifiesto: nada se re-embebe y Chroma se reconstruye desde ella sin llamadas a la API — también en Streamlit Cloud.

Umbral calibrado con datos

Umbral 0,69 leído de las consultas de dominio frente a las de fuera de dominio, no fijado a ojo. Después, filtro por los documentos que nombra la pregunta y cada fragmento ampliado a su sección para que las listas lleguen completas.

Memoria acotada

Checkpointer de LangGraph por thread_id; al modelo llegan los últimos 10 mensajes; los pasajes recuperados viven en el estado, no en el historial.

Gemini 3.5 Flash-Lite · gemini-embedding-2 · ChromaDB · LangGraph · Streamlit — github.com/dnarram

El system prompt: cada versión responde a un fallo observado

V1 · BASE DE CLASE

“Responde a partir de los documentos”

- Correcto y fluido, pero sin marcas de cita: ninguna frase se puede rastrear hasta un pasaje
- Sin regla para la información ausente, sin alcance, sin política de idioma

V3 · CITAS E IDIOMA

[n] en cada frase, fuentes atribuidas, respuesta en el idioma del usuario

- La ejecución del golden set encontró: una pregunta de varios pasos rechazada por completo
- Su rechazo en español, escrito en inglés
- Listas truncadas presentadas como completas

V4 · EN USO

Rechazos graduados, respuestas paso a paso, listas completas

- Responde la parte cubierta y nombra la que no; rechaza solo cuando nada es relevante
- Construye las cadenas paso a paso, citando cada paso
- Da todos los elementos de la lista, o dice que continúa — en el idioma del usuario

Restricciones duras en código, criterio en el prompt. El idioma de la respuesta es una línea determinista en el mensaje del usuario, las preguntas fuera de dominio nunca llegan al modelo, y las listas truncadas se arreglaron en la recuperación (expansión por sección), no con más prompt.

Prompt completo y justificación: README · docs/prompt_iterations.md · v2 fue un paso de diseño, no evaluado aparte

Demo en vivo: cuatro preguntas, cuatro comportamientos

1 · RESPUESTA FUNDADA CON CITAS

What is the timeline for expedited reporting of a fatal unexpected ADR?

Esperado: 7 días naturales + 8 para el informe completo, citado literalmente — ICH E2A §1, p.7. Abrir el panel de fuentes.

2 · MEMORIA + POLÍTICA DE IDIOMA

¿Y para las demás reacciones graves e inesperadas?

Esperado: reescrita como pregunta autónoma en inglés (se muestra en “Searched as”), respondida en español: 15 días naturales.

3 · DOS FUENTES, ATRIBUIDAS POR SEPARADO

¿Qué exigen ICH E6(R3) y la Declaración de Helsinki para incluir a participantes que no pueden dar su consentimiento?

Esperado: nombra ambos documentos, así que el top-6 se reparte entre ellos; E6(R3) Principio 2.1 / §2.8.13 frente a Helsinki ¶28, cada uno con su cita.

4 · RECHAZO, SIN LLAMADA AL MODELO

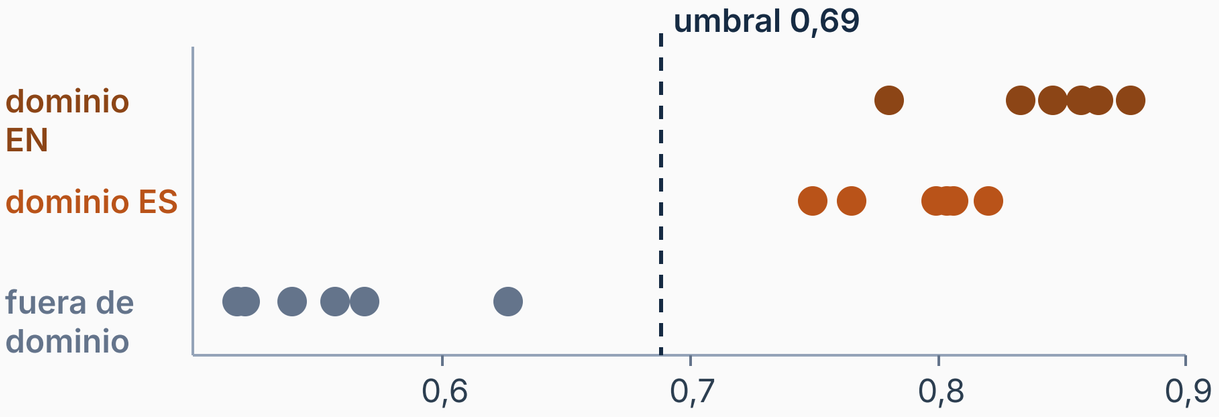
¿Qué fármaco GLP-1 es mejor para perder peso?

Esperado: mejor relevancia ≈0,64, por debajo del umbral 0,69 — “no está en mi base de conocimiento; cubro…”. El modelo que responde nunca vio la pregunta.

Después, una traza nodo a nodo en el notebook (rewrite → retrieve → generate) · Plan B: Streamlit local, notebook ejecutado

Evaluación: corrección juzgada 0,78 → 0,95, confirmada en un conjunto held-out

Mejor relevancia por consulta (top-3, coseno) — 6 pares EN/ES + 6 fuera de dominio



Las consultas en español recuperan los mismos pasajes ~0,04 más abajo; mínimo de dominio 0,75 frente a máximo fuera de dominio 0,63. El umbral es el punto medio de ese hueco y se guarda junto al modelo de embeddings.

GOLDEN SET

Golden: 25 ítems × EN/ES. Held-out: 12 ítems nuevos, escritos tras congelar v4, ejecutados una vez. Juez LLM frente a referencias expertas.

Misma puntuación	v3	v4 final
Juez, golden	0,78	**0,95**
Juez, held-out	0,95	**1,00**
Palabras clave	0,82	**0,97**
Sección EN / ES	0,95 / 1,0	0,95 / 0,95
Fuera de tema	100 %	100 %
Honesto, no indexado	100 %	100 %

`scripts/02_sanity_retrieval.py --calibrate · scripts/03_evaluate.py --with-answers · docs/evaluation.md`

Lo que aún no hace, y lo que viene después

⚠ Limitaciones

- Tres documentos por diseño: EU CTR, módulos GVP y normas FDA se rechazan o se responden solo con lo que dice E6(R3)
- Preguntas de varios saltos: una sola recuperación pierde un salto — la cadena de notificación aún omite el plazo de 15 días
- El umbral de rechazo depende del corpus y del modelo: si cambia uno, recalibrar
- La memoria vive en el proceso; un reinicio olvida los hilos
- Plan gratuito: 1.000 textos embebidos al día — construir el corpus usó 800 una vez, por eso también se cachean los vectores de consulta

⚡ Siguientes pasos, por orden de valor

1. Descomposición de consultas: una recuperación por paso de una pregunta de varios saltos
2. EMA GVP Módulo VI y EU CTR 536/2014 — la ingesta es por documento e idempotente
3. Juez de fidelidad: respuesta frente a pasajes recuperados (el actual mide corrección frente a referencias expertas)
4. Recuperación híbrida (BM25 + vectores) para números de sección y acrónimos exactos
5. Un nodo guard_input (inyección de prompt, PII) y SqliteSaver para hilos persistentes

Gracias — ¿preguntas?

github.com/dnarram/clinical-research-compliance-assistant · app en Streamlit Cloud · información regulatoria, no asesoramiento legal ni médico